

The Anatomy of a Large-scale Hypertextual web search engine

Sergey Brin & Lawrence Page

Exposé de Moteur de recherche

DEA IFA 2004-2005

Leborgne Fabien

Plan

- Introduction.
- Caractéristiques.
- Architecture.
- Composants.
- Conclusion.

Contexte

- L'article:
 - Daté de 1998.
 - Signé par Serge Brin & Lawrence Page.
- Peu de recherche dans ce domaine.
- Première description détaillé d'un moteur.
- Yahoo, altavista,... manque évident.

Pourquoi Google?

- Expansion rapide (pages & utilisateurs)
 - =>croissance du nbr de requêtes
 - =>difficulté pour trouver ce que l'on cherche
- Recherche avec arborescence:
 - Critères subjectifs.
 - Coûte cher (construction & maintenance).
 - Impossible de couvrir tous les sujets.
- Recherche avec Moteur de Recherche:
 - Trop de résultats non voulus.
 - Annonceurs (tromperie volontaire)
- Google = « googol » = 10^{100}

Passage à l'échelle

- Augmentation du nombre de pages
 - 1994 -> 110,000 pages
 - 1997 -> 2,000,000 à 100,000,000 docs
 - prévision 2000 -> x,000,000,000 de docs.
- Augmentation du nombre de requêtes
 - 1994 -> WWW Worm 1500 par jour
 - 1997 -> altavista 20 millions par jour
- Google devra supporter cette croissance.
 - Efficacité
 - Rapidité

Comment passer à l'échelle

■ Efficacité:

- Technique d'exploration (crawl) rapide.
- Utilisation efficace de l'espace de stockage.
- Indexation rapide.
- Réponse rapide aux requêtes.

Qualité des résultats

- Précision de la recherche.
 - PageRank.
 - Utilisation des Ancres.
 - Proximité des termes.
 - Détails de présentation (taille & style de police)

PageRank (1/2)

- Méthode de calcul de l'intérêt d'une page
 - intérêt subjectif calculé à partir de critères objectifs.
- La grande innovation de google.
- Utilise l'arborescence des pages.
- Classement des pages pertinent.

PageRank (2/2)

- Principe de base:

- Formule:

- $PR(A) = (1-d) + d (PR(T1)/C(T1) + \dots + PR(Tn)/C(Tn))$

- L'importance d'une page est déterminé par l'importance des pages qui pointe vers elle.

- Algo itératif.

Les ancres

- Principe:


- Association du texte du lien avec la page pointé.

- Avantages:

- Description précise
- Pages non-crawlable (image, archive, ...)

Architecture

- Serveur d'url.
- Explorateur (crawler).
- Serveur de stockage.
- Indexeur.
- Solveur d'url.
- chercheur(searcher).
- Pagerank.
- Repository.
- Lexique.
- Ancre
- lexique



Composants (1/4)

■ Serveur d'urls:


- Transmission des listes d'urls aux crawler

■ Explorateur(crawler):

- Exploration des pages.
- Envoi des pages au serveur de stockage.
 - +sieurs distribués

■ Serveur de stockage:


- Compression des pages
- Sauvegarde dans le repository
- Nouvelle page associée à un docID.



Composants (2/4)

■ Indexeur:

- Lecture dans la repository.
- Décompression des documents.
- Parsing des pages.
- Conversion des pages en « hit list » (liste d'occurences).
- Distribution des « hits » dans les « barrels » de façon partiellement triée.
- Parsing des url et envoie des informations dans les ancres.
- Création du lexique.




Composants(3/4)

■ Solveur d'url:

- Lecture des ancres.
- Conversion url relative -> url absolue
- Génère la BD de liens utilisé pour le PageRank.

■ Chercheur:

- Exécuté par un serveur web.
- Utilise:
 - Lexique
 - Index
 - PageRank



Composant (4/4)

- Trieur:
 - Création de l'index inverse
 - Triage par wordID
 - Duplication de la mémoire. (cf. indexation)

Structure de données (1/4)

■ Repository:

- Contient les pages HTML
- Utilise Zlib
 - Rapide
 - Ratio 3 to 1 (bzip = 4 to 1)
- Entrée préfixé par DocID , length, URL

Repository: 53.5 GB = 147.8 GB uncompressed

sync	length	compressed packet
sync	length	compressed packet

...


Packet (stored compressed in repository)

docid	ecode	urlen	pagelen	url	page
-------	-------	-------	---------	-----	------

Structure de données (2/4)

■ Lexique:

- 14 millions de mots.
- Liste de mot + table de hachage de pointeur.
- Stockage en mémoire vive (~256MB).



Structure de données(3/4)

■ Hit lists

- Informations:
 - Position
 - Taille police
 - Capitalisation
- Dans les barrels, sur 2 octets.
- Type:
 - Plain -> texte
 - Fancy -> url, titre, texte ancre, meta-tag
 - Ancre -> url (avec docID)

Hit: 2 bytes

plain:	cap:1	imp:3	position: 12	
fancy:	cap:1	imp = 7	type: 4	position: 8
anchor:	cap:1	imp = 7	type: 4	hash:4 pos: 4

Structure de données(4/4)

■ Forward Index:

- Pour chaque document
 - Ensemble des wordid et de leurs hits.
- Trié par docid

■ Reverse index:

- Trié par wordid

Forward Barrels: total 43 GB

docid	wordid: 24	nhits: 8	hit hit hit hit
	wordid: 24	nhits: 8	hit hit hit hit
	null wordid		
docid	wordid: 24	nhits: 8	hit hit hit hit
	wordid: 24	nhits: 8	hit hit hit hit
	wordid: 24	nhits: 8	hit hit hit hit
	null wordid		

...

Lexicon: 293MB

Inverted Barrels: 41 GB

wordid	ndocs	—	→	docid: 27	nhits:5	hit hit hit hit
wordid	ndocs	—	→	docid: 27	nhits:5	hit hit hit
wordid	ndocs	—	→	docid: 27	nhits:5	hit hit hit hit
			→	docid: 27	nhits:5	hit hit

...

Challenge (crawling)

- Interagit avec des centaines de serveurs.
 - Robuste!
- Le crawler de Google:
 - Système distribué avec 3 crawlers
 - ~300 connexions simultanées.
 - ~600KB /sec
 - Appels téléphonique & mail

Challenge (indexing)

- Parser.
 - Support des erreurs dans les pages.
 - Rapide
- Indexer les documents.
 - Rapidité.
 - Structures compactes.
 - Ajout de mots.
- Trier.
 - Génération de l'index inverse.

Résultats

- PageRank:
 - Site officiel « .gov »
- Proximité des termes
 - Pas d'autre bill
- Subjectivité du résultat

Query: bill clinton
<http://www.whitehouse.gov/>
100.00%  (no date) (0K)
<http://www.whitehouse.gov/>
[Office of the President](#)
99.67%  (Dec 23 1996) (2K)
http://www.whitehouse.gov/WH/EOP/OP/html/OP_Home.html
[Welcome To The White House](#)
99.98%  (Nov 09 1997) (5K)
<http://www.whitehouse.gov/WH/Welcome.html>
[Send Electronic Mail to the President](#)
99.86%  (Jul 14 1997) (5K)
http://www.whitehouse.gov/WH/Mail/html/Mail_President.html
<mailto:president@whitehouse.gov>
99.98% 
<mailto:President@whitehouse.gov>
99.27% 
[The "Unofficial" Bill Clinton](#)
94.06%  (Nov 11 1997) (14K)
<http://zpub.com/un/un-bc.html>
[Bill Clinton Meets The Shrinks](#)
86.27%  (Jun 29 1997) (63K)
<http://zpub.com/un/un-bc9.html>
[President Bill Clinton - The Dark Side](#)
97.27%  (Nov 10 1997) (15K)
<http://www.realchange.org/clinton.htm>
[\\$3 Bill Clinton](#)
94.73%  (no date) (4K)
<http://www.gateway.net/~tjohnson/clinton1.html>

Figure 4. Sample Results from Google

Performance

- Espace.
 - Nécessite $\sim 100\text{GB}$
- Rapidité.
 - Réponse entre 1 et 10 secondes:
 - Sans optimisation (cache, algorithme)
- Le but n'était pas d'améliorer la rapidité mais la qualité des résultats.

Conclusion

■ Google

- Passage à l'échelle.
 - Difficile avec l'évolution du web.
- Qualité de la recherche.
 - PageRank, texte des ancres, proximité des termes...
- Rapide et efficace.

Amélioration possible

- Mise en cache des réponses des requêtes.
- Meilleure allocation du disque
- Meilleurs algorithmes.
- Machine dédiée.
- ...
- Ajout d'opérateur (AND, OR, Négation, restriction de la recherche, ...)
- ...

Google aujourd'hui



Web [Images](#) [Groups](#) [News](#) [Froogle](#) [Local](#) ^{New!} [more »](#)

Google Search

I'm Feeling Lucky

[Advanced Search](#)
[Preferences](#)
[Language Tools](#)

[Advertising Programs](#) - [About Google](#) - [Go to Google France](#)

©2005 Google - Searching 8,058,044,651 web pages

In memoriam, [Jef Raskin](#) 1943-2005

Bibliographie

- Sergey Brin, Lawrence Page. The Anatomy of a Large-scale Hypertextual web search engine. Mars 1998.
- Ian Rogers. The Google Pagerank Algorithm.
- Heting Chu, Marilyn Rosenthal. Search Engines for the World Wide Web: A Comparative Study and Evaluation Methodology. Octobre 1996.