

THÈMES DE RECHERCHE APPLIQUÉE

Superviseur: Ir. Charbel MAMLANKOU
Académie des Mathématiques Appliquées (AMA)

1 Généralités

Chaque groupe doit produire un outil fonctionnel répondant à un problème concret, accompagné d'un rapport démontrant une maîtrise complète de la chaîne mathématique du cours. Le code ne constitue jamais une preuve suffisante : toute méthode numérique implémentée doit avoir été justifiée mathématiquement au préalable dans le rapport.

1.1 Pipeline et contraintes

Les quatre projets suivent la même chaîne de raisonnement, illustrée à la Figure 1. Aucun groupe ne peut se limiter à un sous-ensemble du cours : la structure du rapport (Section 1.2) impose de traverser chacun des cinq blocs.




Figure 1: Pipeline méthodologique.

Contrainte méthodologique 1. Le rapport ne contient aucun extrait de code source. Il présente uniquement le développement mathématique, la description de la méthode numérique (pseudo-code accepté) et l'analyse des résultats obtenus. Le code source complet est livré séparément du rapport; toute formule qui y est implémentée (gradient, seuil, critère de convergence, distance, etc.) doit néanmoins avoir été entièrement dérivée à la main dans le rapport avant d'être codée.

Contrainte méthodologique 2. Les problèmes d'optimisation sous contrainte (Sections 2.3 and 2.4) sont traités par pénalisation: ajout d'un terme $\mu \|\cdot\|^2$ pénalisant la violation de contrainte dans la fonction de coût, afin de rester dans le cadre de la descente de gradient (éventuellement projetée) vue en cours, sans recourir aux multiplicateurs de Lagrange.

Contrainte méthodologique 3. Indépendamment du sujet traité, chaque rapport doit contenir explicitement :

- (i) une proposition mathématique justifiée (ex. convexité ou non de J) ;
- (ii) une dérivation complète de $\nabla J(\theta)$;
- (iii) un algorithme (descente de gradient ou variante) correctement justifié ;
- (iv) une validation numérique confrontant explicitement théorie et expérience ;
- (v) une analyse de sensibilité d'au moins un hyperparamètre ;
- (vi) une comparaison à une stratégie de référence (naïve ou non optimisée).

1.2 Structure du rapport

Chaque groupe remet un rapport de type *mini-article* structuré comme suit.

1. **Introduction:** contexte, problématique, motivation, brève revue des approches existantes.
2. **Formulation du problème:** variables, paramètres, hypothèses, contraintes.
3. **Développement mathématique**, couvrant au minimum les cinq volets suivants (l'ordre de présentation est libre, mais les cinq doivent apparaître) :
 - Représentation algébrique (matrices, vecteurs, systèmes, spectre, conditionnement)
 - Modélisation probabiliste (variables aléatoires, lois, espérance, variance)
 - Analyse statistique (estimateurs, intervalles de confiance, tests)
 - Formulation d'optimisation $\min_{\theta} J(\theta)$ et dérivation complète de ∇J
 - Structure discrète (graphe, combinatoire, complexité)
4. **Méthode numérique:** passage explicite mathématiques $\rightarrow$ algorithme, présenté sous forme de pseudo-code uniquement (Contrainte méthodologique 1).
5. **Expériences numériques:** vérification empirique d'au moins deux résultats théoriques établis en partie 3, à partir des résultats produits par le code livré séparément.
6. **Analyse des résultats:** interprétation mathématique, pas seulement descriptive.
7. **Limites et améliorations possibles.**
8. **Conclusion.**
9. **Références bibliographiques.**

2 Thèmes de recherche

2.1 Thème 1: Piloter intelligemment la facture d'électricité d'un bâtiment

Un gérant d'immeuble de bureaux à Cotonou reçoit chaque mois une facture d'électricité de plus en plus lourde, sans jamais vraiment comprendre ce qui la fait varier. Climatisation poussée à fond aux heures les plus chaudes, bureaux allumés alors qu'ils sont vides le week-end, pics de consommation en fin d'après-midi lorsque tout le monde branche son ordinateur en même temps : la facture raconte une histoire que personne ne lit vraiment. Il dispose pourtant de données simples, relevées heure par heure depuis plusieurs mois: température extérieure, nombre d'occupants, consommation mesurée, et aimerait un outil capable non seulement de prédire sa consommation du lendemain, mais aussi de lui suggérer quand agir pour la réduire, sans compromettre le confort des occupants. C'est ce double objectif, prédiction et recommandation, que le groupe doit construire et justifier de bout en bout.

Le point de départ est de représenter les observations horaires sous forme d'une matrice de conception $\mathbf{X} \in \mathbb{R}^{n \times p}$, chaque ligne étant une heure d'observation et chaque colonne une variable explicative. L'étude de la matrice de covariance empirique et de la matrice de corrélation entre ces variables permet de repérer d'éventuelles redondances (la température et l'heure de la journée sont par exemple souvent liées) et de décider, en connaissance de cause, s'il est pertinent de réduire la dimension du problème par une analyse en composantes principales. La consommation elle-même n'est jamais parfaitement prévisible : deux journées en tout point identiques ne donneront jamais exactement la même facture, ne serait-ce qu'à cause de variations de comportement imprévisibles des occupants. Le groupe modélise donc cette consommation comme

$$y = \mathbf{X}\beta + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma^2), \quad (1)$$

un choix de bruit gaussien qu'il doit justifier à partir du théorème central limite; la consommation résiduelle étant elle-même la somme d'un grand nombre de petites perturbations indépendantes (appareils allumés ou éteints aléatoirement, micro-variations de température, etc.). De ce modèle découle naturellement le travail statistique : estimer β , construire un intervalle de confiance sur chacun de ses coefficients pour savoir lesquels sont vraiment significatifs, et examiner les résidus pour vérifier que les hypothèses du modèle tiennent effectivement sur les données observées.

Reste à savoir comment estimer β efficacement, et c'est là qu'intervient l'optimisation. Le groupe travaille avec la fonction de coût régularisée

$$J(\beta) = \frac{1}{n} \|\mathbf{X}\beta - y\|^2 + \lambda \|\beta\|^2, \quad (2)$$

en dérive le gradient $\nabla J(\beta)$, et implémente la descente de gradient qui permet de le minimiser. Mais avant de coder quoi que ce soit, il doit étudier le conditionnement $\kappa(\mathbf{X}^\top \mathbf{X})$ de son jeu de données, comprendre pourquoi des variables d'échelles très différentes (une température en degrés, un nombre d'occupants en unités) peuvent transformer la descente de gradient en une lente oscillation dans un ravin, et montrer comment le terme de régularisation λ agit précisément sur ce conditionnement. Enfin, pour transformer la prédiction en véritable recommandation, le groupe construit un graphe des états horaires possibles du bâtiment: chaque nœud représentant une combinaison discrétisée d'heure, d'occupation et de température, et recherche, sur ce graphe, la séquence d'états qui minimise la consommation cumulée d'une journée type. Le graphe n'est pas ici un simple schéma décoratif : c'est lui qui produit directement la recommandation finale soumise au gérant de l'immeuble.

Livrable attendu: Un outil de prédiction de la consommation horaire, assorti d'un intervalle de confiance, capable de recommander des créneaux concrets de réduction fondés sur le graphe d'états construit.

2.2 Thème 2: Éviter l'arrêt d'une chaîne de production grâce à la détection d'anomalies

Dans une petite unité de transformation industrielle (huilerie, unité textile, brasserie), une machine tombe en panne sans prévenir en pleine production, interrompant toute la chaîne pendant plusieurs heures et coûtant bien plus cher que si l'anomalie avait été repérée à temps. L'usine a pourtant installé plusieurs capteurs sur ses équipements: température, vibration, pression, courant électrique, mais personne ne sait vraiment exploiter ce flot continu de mesures pour distinguer une simple fluctuation normale d'un signal avant-coureur de panne. Le responsable de maintenance aimerait un système qui déclenche une alerte uniquement quand c'est vraiment nécessaire, sans noyer les opérateurs sous de faux positifs, et qui indique en plus quel composant est probablement en cause. C'est précisément ce système, de la représentation des capteurs au diagnostic final, que le groupe doit construire.

Les mesures des p capteurs à chaque instant forment un vecteur $\mathbf{X} = (x_1, \dots, x_p)$, et l'ensemble des observations une matrice $\mathbf{X} \in \mathbb{R}^{n \times p}$. Les capteurs étant rarement indépendants entre eux, une hausse de température s'accompagne souvent d'une hausse de vibration, le groupe étudie d'abord la matrice de covariance de ces capteurs, puis en extrait, par SVD ou par analyse en composantes principales, une représentation réduite $\mathbf{Z} = \mathbf{XV}_k$ dans laquelle la distance de Mahalanobis d'une observation à son centre devient un indicateur naturel d'anormalité. Mais mesurer une distance ne suffit pas à décider si une observation est vraiment une anomalie : il faut raisonner en termes de probabilité. Le groupe formalise donc la décision par le théorème de Bayes,

$$\mathbb{P}(A | \mathbf{X}) = \frac{\mathbb{P}(\mathbf{X} | A) \mathbb{P}(A)}{\mathbb{P}(\mathbf{X})}, \quad (3)$$

et doit discuter, chiffres à l'appui, un phénomène contre-intuitif mais essentiel : lorsque les pannes sont rares (faible prévalence $\mathbb{P}(A)$), même un capteur très performant peut produire une majorité de fausses alertes.

Cette tension entre alertes manquées et fausses alertes a un coût réel pour l'usine : un arrêt de production non nécessaire coûte cher, une panne non détectée coûte plus cher encore. Le groupe formalise ce compromis par une fonction de coût du seuil de décision θ ,

$$J(\theta) = C_{FP} \mathbb{P}(FP; \theta) + C_{FN} \mathbb{P}(FN; \theta), \quad (4)$$

et recherche le seuil $\theta^* = \arg \min_{\theta} J(\theta)$ minimisant ce coût global, en justifiant la méthode retenue selon que J est ou non différentiable en θ . Les taux de faux positifs et de faux négatifs, la précision et le rappel sont ensuite estimés statistiquement, avec un intervalle de confiance par bootstrap pour rendre compte de l'incertitude de ces estimations. Enfin, pour que l'alerte déclenchée soit vraiment utile à l'équipe de maintenance, le groupe construit un graphe causal reliant chaque capteur aux composants qu'il surveille, puis aux modes de panne possibles, et recherche sur ce graphe le chemin causal le plus probable menant à l'anomalie observée : c'est ce chemin qui donne au responsable de maintenance une piste concrète d'intervention.

Livrable attendu: Un détecteur d'anomalies doté d'un seuil de décision optimisé θ^* , capable d'accompagner chaque alerte d'un diagnostic de cause probable.

2.3 Thème 3: Distribuer l'eau équitablement dans un quartier quand la demande est incertaine

Une société de distribution d'eau alimente plusieurs quartiers d'une ville à partir de quelques réservoirs, reliés par un réseau de conduites dont le débit n'est pas illimité. Certains quartiers sont systématiquement mieux servis que d'autres, non par mauvaise volonté, mais simplement parce que la répartition actuelle de l'eau est faite à l'ancienne, sans véritable optimisation, et parce que la demande de chaque quartier varie d'un jour à l'autre de façon imprévisible: événement local, chaleur inhabituelle, coupure ponctuelle chez un voisin qui reporte la demande ailleurs. L'ingénieur chargé du réseau aimerait un outil capable de proposer une répartition plus équitable et moins coûteuse de l'eau disponible, qui reste fiable même lorsque la demande réelle s'écarter des prévisions. C'est ce problème, posé sur un réseau simplifié mais réaliste, que le groupe doit résoudre.

Le réseau lui-même se prête naturellement à une représentation par un graphe $G = (V, E)$, dont les nœuds sont les réservoirs et les quartiers, et les arêtes les conduites qui les relient. La matrice d'incidence de ce graphe et l'étude de sa connexité permettent de vérifier qu'aucun quartier n'est isolé du reste du réseau, et de repérer les points de fragilité (un quartier relié par une seule conduite, par exemple). Cette structure discrète se traduit algébriquement par un système linéaire de conservation des flux $\mathbf{A}\mathbf{q} = \mathbf{b}$, où $\mathbf{q}$ représente les débits sur chaque conduite ; le groupe étudie le rang de $\mathbf{A}$ et son conditionnement, et montre comment un réseau mal maillé, trop peu de conduites reliant les quartiers entre eux (se traduit directement par une instabilité numérique de la résolution).

La difficulté principale reste que la demande D_i de chaque quartier i n'est jamais connue à l'avance avec certitude. Le groupe la modélise comme une variable aléatoire,

$$D_i \sim \mathcal{N}(\mu_i, \sigma_i^2), \quad (5)$$

et simule par Monte-Carlo un grand nombre de scénarios de demande possibles, ce qui permet d'estimer statistiquement la demande moyenne, sa variance, les corrélations entre quartiers voisins, et de repérer les quartiers dont la demande s'écarter régulièrement des prévisions. Une fois cette incertitude quantifiée, il reste à déterminer la répartition optimale de l'eau, c'est-à-dire à résoudre

$$\mathbf{q}^* = \arg \min_{\mathbf{q}} \sum_{e \in E} c_e q_e^2 \quad \text{sous} \quad \mathbf{A}\mathbf{q} = \mathbf{b}, \quad \mathbf{q} \geq 0. \quad (6)$$

Conformément à la Contrainte méthodologique 2, la contrainte d'égalité est traitée par pénalisation,

$$J(\mathbf{q}) = \sum_{e \in E} c_e q_e^2 + \mu \|\mathbf{A}\mathbf{q} - \mathbf{b}\|^2, \quad (7)$$

et la contrainte de positivité $\mathbf{q} \geq 0$ par projection à chaque étape de la descente de gradient, une simplification que le groupe doit justifier explicitement dans son rapport.

Livrable attendu: Une comparaison chiffrée entre la distribution actuelle du réseau (proportionnelle aux demandes) et la distribution optimisée $\mathbf{q}^*$, testée sur plusieurs scénarios de demande simulés.

2.4 Thème 4: Organiser l'évacuation d'un quartier menacé par une inondation

Chaque saison des pluies, un quartier côtier exposé aux inondations doit parfois être évacué en urgence vers des points de rassemblement plus sûrs. Le service de protection civile responsable de cette opération ne dispose aujourd'hui d'aucun plan réellement optimisé : les habitants sont orientés vers la sortie la plus proche sans tenir compte du fait que certaines routes se congestionnent rapidement, que certains itinéraires sont plus risqués que d'autres en cas de crue soudaine, et que les temps de trajet réels varient fortement d'un jour à l'autre selon l'état des routes. Le responsable souhaite un outil d'aide à la décision capable de proposer, avant même qu'une crue ne survienne, une répartition de la population vers les différentes sorties qui minimise à la fois le temps d'évacuation et le risque encouru, et qui reste fiable même quand les conditions réelles s'écartent des prévisions. C'est ce plan d'évacuation que le groupe doit concevoir et valider.

Le réseau routier du quartier, bâtiments, carrefours, sorties, se représente naturellement comme un graphe $G = (V, E)$. Le calcul des plus courts chemins entre chaque bâtiment et chaque sortie, ainsi que l'étude de la connexité du réseau et de la capacité maximale de chaque sortie, constituent le socle sur lequel repose tout le reste du projet. Cette structure se traduit algébriquement par une matrice d'adjacence ou d'incidence du réseau routier et par un vecteur de population associé à chaque nœud, qui permettent de représenter matriciellement les flux d'évacuation envisagés. Mais un plan d'évacuation conçu sur des temps de trajet supposés exacts serait dangereusement naïf : en réalité, chaque trajet T_{ij} entre deux points du réseau est incertain,

$$T_{ij} \sim \mathcal{D}(\mu_{ij}, \sigma_{ij}^2), \quad \mathbb{P}(R_{ij}) \text{ modélisée explicitement}, \quad (8)$$

où $\mathcal{D}$ désigne une loi que le groupe doit choisir et justifier: une gaussienne tronquée ou une loi log-normale, par exemple, afin d'exclure tout temps de trajet négatif, ce qu'une gaussienne non tronquée autoriserait.

L'incertitude sur les temps de trajet ne se contente pas d'être modélisée : elle doit être quantifiée par simulation. Le groupe fait tourner des simulations de Monte-Carlo à trois échelles croissantes (100, puis 1 000, puis 10 000 tirages), en estime la moyenne et la variance du temps d'évacuation, ses quantiles, la probabilité $\mathbb{P}(T_{\text{évac}} < t)$ pour un seuil de temps critique t fixé par les autorités, et compare statistiquement deux stratégies d'évacuation candidates à l'aide d'un test d'hypothèse. Reste enfin à choisir, parmi toutes les affectations possibles de la population aux différentes sorties, celle qui réalise le meilleur compromis entre temps, risque et congestion :

$$J(x) = \alpha T(x) + \beta R(x) + \gamma C(x). \quad (9)$$

Le groupe optimise une relaxation continue de cette affectation x des proportions de population dirigées vers chaque sortie, par descente de gradient, avant de discrétiser le plan final en instructions concrètes pour les équipes de terrain.

Livrable attendu: Une comparaison, aux trois échelles de simulation retenues, entre une stratégie d'évacuation naïve et la stratégie optimisée, accompagnée d'une analyse statistique de sa robustesse.

3 Grille d'évaluation

La correction porte, pour les quatre groupes, sur la même grille en sept rubriques, ce qui garantit la comparabilité malgré des sujets différents.

Rubrique	Critère d'évaluation	Poids%
Formulation du problème	Clarté des variables, hypothèses, contraintes	10 %
Algèbre linéaire	Représentation matricielle, spectre, conditionnement	15 %
Probabilités & statistiques	Modélisation, estimateurs, IC, tests	20 %
Optimisation	Dérivation du gradient, convergence, expérimentation	20 %
Mathématiques discrètes	Usage réel (non cosmétique) du graphe/de la combinatoire	10 %
Implémentation & validation	Qualité du code livré, confrontation théorie/expérience	15 %
Rédaction & rigueur	Structure, notations, discussion des limites	10 %
Total		100 %

Table 1: Grille de notation.